Limbajul în Știință și Tehnologie: O Privire de Ansamblu

Autor: Ionică Andrei

Academia de Studii Economice București,
Facultatea de Cibernetică, Statistică și Informatică Economică

Rezumat: În această lucrare, analizăm limbajul utilizat în inteligența artificială (AI), concentrându-ne inițial pe un domeniu specific – AI în agricultură. Studiul se bazează pe analiza textuală a unor surse diverse, precum articole științifice, descrieri de proiecte finanțate de Uniunea Europeană, brevete și pitch-uri ale companiilor. Pentru a identifica și compara termenii specifici domeniului, aplicăm tehnici de extragere a cuvintelor-cheie utilizând algoritmi avansați de procesare a limbajului natural.

Demersul continuă prin antrenarea și compararea mai multor modele de clasificare, inclusiv Multinomial Naive Bayes (MNC), Complement Naive Bayes (CMB) și Support Vector Classifier (SVC), selectând modelul optim pentru analiza ulterioară. După validare, extindem cercetarea către alte domenii tehnologice, folosind modelul ales pentru a identifica tipare și corelații în limbajul utilizat în articole științifice, brevete, proiecte europene și descrieri ale companiilor. Rezultatele obținute contribuie la înțelegerea modului în care este structurat și evoluează limbajul sectorul tehnologic.

Cuvinte cheie: AI, NLP, LDA, TextRank, TF-IDF

1. Introducere

În diverse domenii, inteligența artificială este tot mai prezentă, iar articolele științifice, brevetele, proiectele europene și prezentările companiilor reflectă această evoluție printr-un limbaj variat și specializat.

Scopul acestei lucrări este de a analiza limbajul utilizat în surse diverse, precum articole științifice, brevete, proiecte europene și prezentări ale companiilor, pentru a identifica tipare, termeni-cheie și conexiuni relevante între domenii.

2. Surse date și selecție

Perspectiva de analiză are ca punct inițial și principal de plecare preluarea din surse de date de încredere a înregistrărilor necesare în procesul de prelucrare. Aceste surse de date definesc mai multe etape în care este prezentă latura de cercetare și anume: domeniul articolelor de specialitate, domeniul proiectelor de cercetare, domeniul patentelor, precum și domeniul startup-urilor ca sursă de diseminare a cercetării.

- **WOS** (Web Of Science) este o bază de date bibliografică ce conține articole științifice din reviste de top, acoperind multiple domenii.
  Metodă selecție: Căutare avansată după termeni specifici (ex: AI, crop, farm, etc..)
  Rezultat: 33473 articole - doar pentru AI în agricultură
- **CORDIS** (Community Research and Development Information Service) este baza de date a Comisiei Europene care conține informații despre proiectele de cercetare finanțate de UE.
  Metodă Selecție: script Python care a filtrat proiectele între 1984-2027, reținând doar cele cu termeni relevanți.
  Rezultat: 1147 articole
- **WIPO** (World Intellectual Property Organization) este o bază de date internațională care conține brevete depuse la nivel global.
  Metodă Selecție: Căutare avansată în Patentscope, utilizând termeni-cheie legați de AI și agricultură.
  Rezultat: 955 articole
- **Crunchbase** este o platformă de date despre companii, oferind informații despre finanțare, investiții și creșterea startup-urilor.
  Metodă Selecție: Căutare avansată utilizând termeni-cheie legați de AI și agricultură.
  Rezultat: 825 articole
- **Y Combinator** este un accelerator de startup-uri care oferă finanțare și mentorat companiilor inovatoare, majoritatea dintre acestea fiind axate pe tehnologie și AI.
  Metoda de selecție: Un script Python a extras pitch-uri și descrieri pentru primele 1000 startup-urilor, fără restricții specifice.
  Rezultat: 1000 articole

3. Analiză cuvinte

Pentru a înțelege mai bine limbajul folosit în sursele analizate, am extras și analizat cuvintele-cheie, identificând tipare și suprapuneri între domenii. Procesul a început cu o curățare a textelor, eliminând stopwords, aplicând lematizare și standardizând formatul cuvintelor.

Am considerat următorii algortimi:

- **LDA** (Hamed Jelodar, et al., 2018) (Latent Dirichlet Allocation) este un algoritm probabilistic folosit pentru descoperirea automată a temelor într-un set de documente. Fiecare document conține o combinație de teme, iar fiecare temă este definită de un set de cuvinte reprezentative.

Avantaje: Identifică structuri latente în texte mari, Eficient, nu trebuie antrenat
Dezavantaje: Sensibil la numărul de teme - trebuie abuzat ca să scoată cuvinte individuale, Nu funcționează bine pe texte scurte

- **TextRank** (Mihalcea Rada & Paul Tarau, 2004) este un algoritm inspirat din PageRank, utilizat pentru extragerea automată de cuvinte-cheie și sumarizarea textelor prin reprezentarea acestora sub formă de graf.
  Avantaje: Performanta buna pe texte mici-medii, Nu trebuie antrenat
  Dezavantaje: Mai lent, Sensibil la parametrizarea inițială.
- **RAKE** (J.S. Baruni & Dr. J.G.R. Sathiaseelan, 2020) (Rapid Automatic Keyword Extraction) este un algoritm nesupervizat pentru extragerea cuvintelor-cheie, bazat pe identificarea frecvenței și co-ocurenței termenilor dintr-un text.
  Avantaje: Rapid si eficient, Nu trebuie antrenat
  Dezavantaje: Nu captează contextul semantic, Sensibil la alegerea de stopwords, Detectează fraze, nu cuvinte - trebuie abuzat ca să scoată cuvinte individuale
- **TF-IDF** (Ramos, 2003) este o metodă statistică folosită pentru a evalua importanța unui cuvânt într-un document, relativ la un set de documente. Se bazează pe două componente, TF(term frequency) si IDF(inverse document frequency).
  Avantaje: Rapid si eficient, Nu trebuie antrenat
  Dezavantaje: Necesita corpus mare, Nu captează relațiile dintre cuvinte

Am ales TextRank deoarece oferă rezultate bune fără antrenare prealabilă și funcționează eficient pe texte de dimensiuni variate. Spre deosebire de TF-IDF, care necesită un corpus mare, și LDA, care este sensibil la parametri, TextRank identifică cuvinte-cheie analizând relațiile dintre termeni, nu doar frecvența lor.

Pentru a organiza și analiza eficient cuvintele-cheie extrase, am folosit o bază de date SQLite. Am structurat tabela keywords astfel încât să stocăm fiecare cuvânt împreună cu sursa sa (origin), prevenind duplicatele prin constrângerea UNIQUE(keyword, origin). Această abordare ne-a permis să comparăm vocabularul diferitelor surse și să identificăm suprapunerile relevante între domenii.

Rezultate finale: Cordis – 1626 cuvinte cheie, Crunchbase – 2579 cuvinte cheie, WIPO – 2497 cuvinte cheie, WOS – 21080 cuvinte cheie

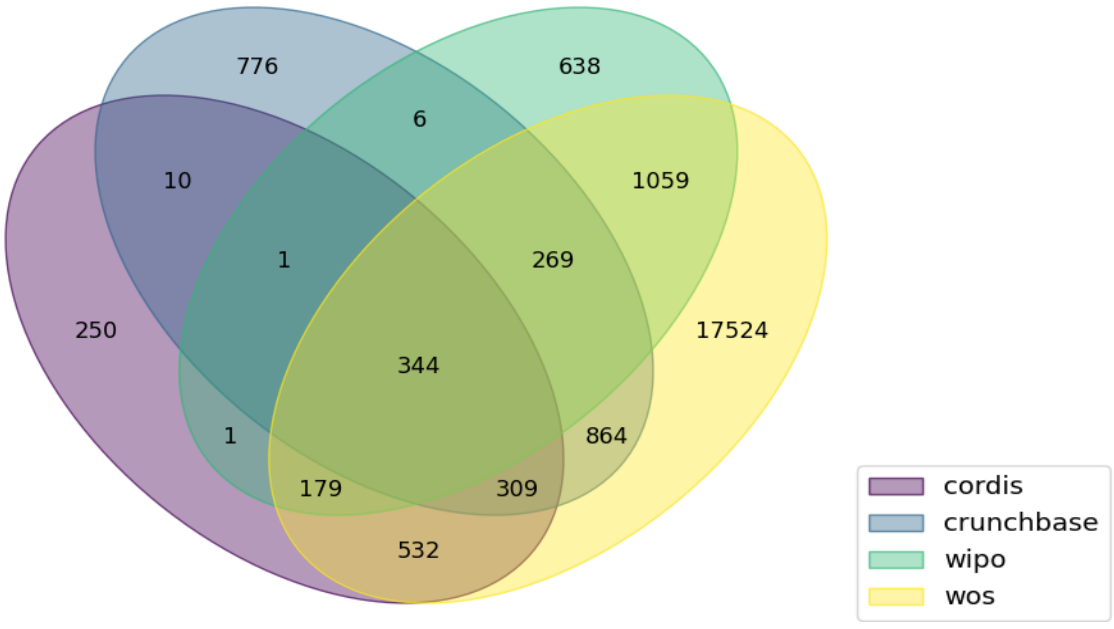


Fig. 1 Diagrama Venn a bazei de date

În Figura 1 este ilustrată suprapunerea vocabularului dintre sursele analizate sub forma unui diagramă Venn, evidențiind cuvintele comune și specifice fiecărui set alături de legenda corespunzătoare, explicând culorile și categoriile reprezentate. Perspectiva de analiză propusă conduce la următoarele concluzii preliminare:

- Există 344 de cuvinte comune tuturor surselor;
- Setul WOS are cel mai mare vocabular unic, datorat și de dimensiunea sa disproporționat de mare;
- WOS și fiecare dintre cele 3 seturi au o suprapunere mare(relativ la al doilea set);
- Cordis, WIPO și Crunchbase la intersectarea 2-cate-2 prezintă o suprapunere de 500-600 de cuvinte, procentual 24%, respectiv 35%;
- Intersectia tuturor Cordis, WIPO și Crunchbase este aceeasi cu intersectia intre toate cele 4.

Vocabularul comun dintre proiectele UE (Cordis), companii (Crunchbase) și patente (WIPO) indică o legătură între finanțare, inovare și aplicabilitate comercială, cu o suprapunere de 24-35% – nu foarte mare, dar nici neglijabilă.

Acest lucru sugerează că, deși fiecare domeniu are un limbaj specific, există un nucleu comun, probabil legat de tehnologie și business. Literatura științifică (WOS), deși mult mai extinsă, păstrează această intersecție, arătând că cercetarea academică influențează atât dezvoltarea tehnologică, cât și aplicabilitatea practică a inovațiilor.

4. Model Clasificare

Pentru a analiza și organiza datele, am folosit mai multe modele de clasificare, fiecare cu avantaje specifice. Modelele utilizate sunt Support Vector Classification (SVC) (Deep, 2020), Multinomial Naive Bayes (MNB) și Complement Naive Bayes (CNB) (Gan, 2021). Acestea sunt populare în clasificarea textelor, deoarece pot învăța tipare din date și oferi predicții precise.

Preprocesarea textelor – Am eliminat caractere speciale, am aplicat tokenizare și eliminare de stopwords pentru a îmbunătăți calitatea datelor de antrenare.

Vectorizarea textelor – Am transformat textele în reprezentări numerice folosind TF-IDF Vectorizer din Scikit-learn.

Antrenarea modelelor – Am folosit Scikit-learn pentru a antrena modelele SVC, MNB și CNB, utilizând seturile de date etichetate conform sursei lor.

O matrice de confuzie prezintă performanța unui model de clasificare, comparând predicțiile cu valorile reale. Fiecare rând reprezintă clasele reale, iar fiecare coloană clasele prezise. Elementele diagonale indică predicțiile corecte, iar cele din afara diagonalei sunt erori.

SVC este o metodă bazată pe Support Vector Machines (SVM), utilizată pentru clasificarea binară și multi-clasă. Modelul funcționează prin găsirea unui hiperplan optim care separă categoriile de date cu cea mai mare marjă posibilă. Avantajele metodei sunt reprezentate de rezistența la date zgomotoase, foarte bun pentru clasificare text însă algoritmul este costisitor în procesul de rulare.

MNB este o variantă a Naive Bayes optimizată pentru date discrete, precum frecvențele de cuvinte în clasificarea textelor. Modelul presupune că fiecare caracteristică contribuie independent la probabilitatea unei clase. Chiar dacă algoritmul este rapid și eficient, este sensibil la dezechilibrul de clase, nu captează relații între cuvinte.

CNB este o variantă îmbunătățită a Naive Bayes, concepută special pentru a gestiona problema dezechilibrului între clase. În loc să estimeze direct probabilitatea unui cuvânt într-o clasă, CNB învață din complementul acelei clase. Este un algoritm ezistent la clase nebalansate, rapid și eficient dar nu reușește să capteze relații între cuvinte.

Figurile 2, 3 și 4 prezintă rezultatele furnizate de analiza clasificatorilor SVC, MCB și CNB.

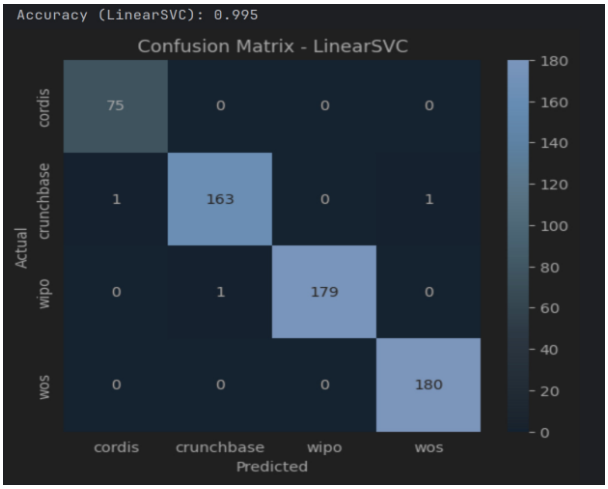


Fig. 2 Confusion Matrix pentru SVC

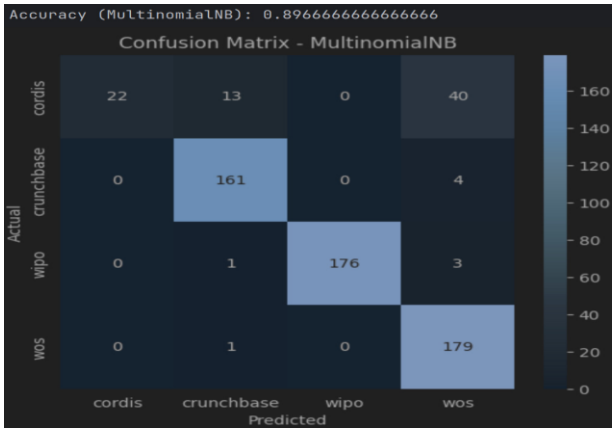


Fig. 3 Confusion Matrix pentru MNB



Fig. 4 Confusion Matrix pentru CNB

Din matricea de confuzie se observă faptul că LinearSVC oferă cele mai bune rezultate, având cele mai multe predicții corecte pe diagonala principală și cele mai puține erori. Comparativ cu

celelalte modele, acesta obține o acuratețe mai mare, indicând că separă mai eficient clasele din setul de date analizat.

5. Analiza generală

După antrenarea modelului SVC pe seturile de date inițiale (articole științifice, brevete, proiecte, startup-uri), am realizat o analiză mai amplă pentru a verifica capacitatea modelului de a clasifica texte similare, dar nu identice cu cele de antrenare. Astfel, am testat modelul pe noi seturi de date.

1. Analiza Companii
    a. Scop: Analiza limbajului utilizat de companiile din domeniul tehnologiei.
    b. Selecția datelor: Am utilizat un script Python pentru a descărca descrierile companiilor finanțate de Y Combinator, accesând API-ul lor intern.
    c. Restricții de căutare: Nu au fost impuse, deoarece toate companiile incluse sunt axate pe tehnologie.
    d. Rezultat: Acuratețe 96%
    e. Concluzie: Acuratețea sugerează că termenii și structurile lingvistice din descrierile startup-urilor din tehnologie se aliniază în mare măsură cu cele din seturile de antrenare, ceea ce reflectă tendința generală a sectorului de a adopta un vocabular comun.
2. Analiza Patente
    a. Scop: Analiza limbajului utilizat în brevetele asociate proiectelor europene din toate domeniile.
    b. Selecția datelor: Am extras abstractele și descrierile brevetelor din WIPO, selectând toate cele asociate cu proiecte europene.
    c. Restricții de căutare: Nu au fost aplicate filtre suplimentare, păstrând toate domeniile tehnologice.
    d. Rezultat: Acuratețe pe abstract 61%, Acuratețe pe descriere 73%
    e. Concluzie: Acuratețea de peste 50% indică un anumit grad de suprapunere între limbajul brevetelor la nivel mai general și cel din seturile de antrenare. Totuși, scorurile mai scăzute comparativ cu analiza companiilor sugerează diferențe semnificative între modul de redactare al brevetelor și al celorlalte surse. În plus, descrierile mai lungi au condus la o acuratețe mai mare, ceea ce sugerează că modelele beneficiază de un context extins.
3. Analiza Articole stiintifice
    a. Scop: Analiza limbajului utilizat în articolele științifice din diverse domenii tehnologice.
    b. Selecția datelor: Am extras articole din WOS, selectând trei seturi distincte: articole pe tema AI, articole din domeniul agriculturii și un set mai larg din domeniul tehnologiei.
    c. Restricții de căutare: Căutările au fost realizate folosind termeni relevanți pentru fiecare domeniu, fără alte restricții.
    d. Rezultat: Acuratețe pe domeniul AI 98%, Acuratețe pe agricultură AI 93%, Acuratețe pe domeniul mai larg „tehnologie” 96%
    e. Concluzie: Acuratețea ridicată pentru toate seturile (între 93% și 98%) sugerează o corelație puternică între limbajul utilizat în articolele științifice, indiferent de subdomeniul tehnologic. Aceasta poate fi influențată și de structurile rigide și formale impuse de mediul academic.

6. Concluzii

Această cercetare a explorat utilizarea tehnicilor de procesare a limbajului natural și învățare automată pentru a analiza limbajul din diverse surse de date, inclusiv articole științifice, patente,

companii și proiecte europene. Modelele de clasificare, precum SVC, CNB și MNB, au obținut acurateţe variabilă, de la 61% pentru patente, până la 98% pentru articolele pe domeniul AI, indicând o corelație puternică între limbajul folosit în diverse domenii tehnice și științifice. De asemenea, s-a observat că lungimea textului are un impact semnificativ asupra performanței, modelele având rezultate mai bune pe texte mai detaliate.

În ansamblu, rezultatele sugerează că tehnologiile de învățare automată pot fi folosite eficient pentru analiza limbajului în domenii variate, iar modelele antrenate pot fi extinse și adaptate pentru alte surse de date. Aceste descoperiri contribuie la înțelegerea modului în care limbajul evoluează în contextul tehnologic și științific, având potențialul de a îmbunătăți analiza documentației în cercetare și dezvoltare.

7. Direcții de Dezvoltare Viitoare

O direcție importantă pentru viitor ar fi să extindem cercetarea către mai multe domenii și surse de date. Putem analiza limbajul din alte sectoare, cum ar fi medicina sau educația, unde comunicarea este esențială.

Un alt domeniu de dezvoltare viitoare ar fi crearea unui chatbot capabil să detecteze tipul de utilizator cu care interacționează pe baza limbajului utilizat și să își adapteze stilul de comunicare în funcție de acesta. Acesta ar putea analiza nu doar cuvintele folosite, ci și tonul și structura frazelor, oferind astfel o experiență mai personalizată în comunicare.

8. Bibliografie

1. Deep, K. (2020). Text -Classification of 20Newsgroups Data Set. *International Journal of Advanced Research in Arts, Science, Engineering & Management (IJARASEM), 7*(5). Preluat de pe https://ijarasem.com/admin/img/5_Text.pdf
2. Gan, S. S. (2021). Adapting Hidden Naive Bayes for Text Classification. *Mathematics, 9*(19), 2378. doi:https://doi.org/10.3390/math9192378
3. Hamed Jelodar, Yongli Wang, Chi Yuan, Xia Feng, Xiahui Jiang, Yanchao Li, & Liang Zhao. (2018). Latent Dirichlet allocation (LDA) and topic modeling: models, applications, a survey. *Springer Nature*, 15169-15211.
4. J.S. Baruni, & Dr. J.G.R. Sathiaseelan. (2020). Keyphrase Extraction from Document Using RAKE and TextRank Algorithms. *International Journal of Computer Science and Mobile Computing*, 83-93.
5. Mihalcea Rada, & Paul Tarau. (2004). TextRank: Bringing Order into Texts. *2004 Conference on Empirical Methods in Natural Language Processing* (pg. 404-411). Barcelona: Association for Computational Linguistics.
6. Ramos, J. (2003). Using tf-idf to determine word relevance in document queries. *Proceedings of the first instructional conference on machine learning*, (pg. 29-48).